

Módulo 4

Aula 1: Scatter Plots

Questão 1

No contexto da visualização de dados, o fenômeno do *overplotting* em gráficos de dispersão tradicionais configura um problema crítico para a análise exploratória. Assinale a alternativa que descreve corretamente o impacto do *overplotting* e a solução adequada apresentada no material:

- a) Ele causa dispersão excessiva e desconexa dos pontos, e a solução ideal é remover os outliers da amostra.
- b) Ele gera uma sobreposição de pontos que dificulta a interpretação, ocultando a real densidade dos dados; a aplicação do parâmetro *alpha* ou o uso de um gráfico *Hexbin* ajudam a solucionar este problema.
- c) Ele impede a criação de variáveis categóricas, e a única alternativa viável é a transformação logarítmica do eixo X.
- d) Ele simplifica excessivamente a imagem visual, e a melhor solução é aplicar linhas de regressão segmentadas.
- e) Ele altera a escala numérica do eixo Y, e a correção recomendada é a padronização via Z-score.

Questão 2

Uma analista de dados possui um grande volume de dados e deseja avaliar a densidade e o agrupamento das observações de forma limpa e organizada, sem sofrer com a poluição visual provocada pelo acúmulo de pontos individuais sobrepostos. De acordo com a comparação das técnicas de visualização, qual é a ferramenta mais indicada para essa situação?

- a) Scatter Plot tradicional.
- b) Gráficos de pizza tridimensionais.
- c) Hexbin Plot.
- d) Boxplot segmentado por categorias.
- e) Gráfico de Linhas Clássico.

Aula 2: Regressão (Regplot e Lmplot)

Questão 3

A análise de regressão é uma ferramenta estatística e visual de grande valor em ciência de dados. Com base nas definições das principais ferramentas visuais aplicadas para este fim, assinale a alternativa correta:

- a) O regplot é focado no isolamento de séries temporais não numéricas.
- b) O lmpplot é idêntico ao regplot em todas as suas dimensões, diferindo apenas porque o lmpplot proíbe o uso de scatter plots.
- c) O regplot cria um scatter plot com uma linha de regressão, sendo ideal para análises rápidas, enquanto o lmpplot possui funções similares, mas permite também separar dados por categorias.
- d) Ambas as ferramentas eliminam automaticamente a incerteza do modelo, dispensando qualquer representação visual de variabilidade.
- e) O intervalo de confiança não pode ser associado à linha gerada por nenhuma dessas duas funções.

Questão 4

Ao observar uma linha de regressão em um gráfico gerado no Python, nota-se uma área sombreada ao redor da reta de tendência. Essa região representa o Intervalo de Confiança (*Confidence Interval*). Visualmente, o que a largura dessa faixa sombreada indica para o analista?

- a) Indica a quantidade total de outliers que foram excluídos da base de dados original.
- b) Indica a incerteza da estimativa, sendo que, quanto menor for a faixa sombreada, maior será a confiança no modelo estatístico apresentado.
- c) Mostra a taxa de crescimento acumulado de uma variável ao longo de um eixo temporal indexado.
- d) Sinaliza a quantidade de categorias em que os dados foram divididos.
- e) Representa o valor fixo do coeficiente linear, independentemente do volume de dados amostrado.

Aula 3: Séries Temporais I

Questão 5

As Séries Temporais são amplamente aplicadas para analisar dados organizados cronologicamente. Na biblioteca Pandas, qual função é destacada como a principal ferramenta para converter strings ou outros formatos em objetos nativos de data, permitindo tarefas como filtrar períodos, ordenar datas e agrupar dados pelo tempo?

- a) `pd.to_dataframe()`
- b) `pd.to_datetime()`
- c) `pd.set_time_index()`
- d) `pd.convert_dates()`
- e) `pd.group_by_time()`

Questão 6

O conceito de sazonalidade desempenha um papel fundamental no entendimento de dados temporais. Qual das alternativas a seguir define corretamente a sazonalidade e seu benefício metodológico segundo o material de estudo?

- a) É a completa ausência de padrões recorrentes, ajudando a identificar erros de amostragem na coleta dos dados.
- b) São padrões aleatórios que ocorrem apenas uma vez na história de uma empresa, servindo para identificar picos de crises.
- c) São padrões que se repetem em determinados períodos (como vendas maiores no final do ano), auxiliando no entendimento de comportamentos recorrentes nos dados.
- d) É a variação de dados causada pela mudança nos parâmetros de transparência *alpha*.
- e) Trata-se da tendência linear de longo prazo que desconsidera as divisões de meses ou horários específicos.

Aula 4: Séries Temporais II

Questão 7

Os gráficos de área (*Area Charts*) são recursos visuais muito utilizados na análise de séries temporais. Qual é a sua principal característica gráfica e sua maior utilidade prática?

- a) Eles dividem a tela em múltiplos quadrantes por categorias de forma isolada e sem eixos comuns.
- b) Eles ocultam os dados históricos para focar apenas nas previsões futuras geradas por algoritmos de Machine Learning.
- c) Eles mostram a evolução dos dados ao longo do tempo, preenchendo visualmente a região abaixo da linha, sendo muito úteis para visualizar o crescimento acumulado.
- d) Eles servem exclusivamente para substituir os scatter plots tradicionais quando o volume de dados é excessivamente baixo.
- e) Eles removem as linhas do gráfico, utilizando apenas hexágonos cuja intensidade visual indica a densidade.

Questão 8

Em visualizações de dados, em particular para séries temporais, a configuração do eixo Y pode influenciar fortemente a percepção do leitor. Sobre a importância da "Base Zero" no eixo Y, assinale a alternativa correta:

- a) A base zero deve ser evitada porque sempre distorce as tendências reais ocultando os padrões acumulados.
- b) Iniciar o gráfico com base zero no eixo Y evita distorções visuais na interpretação e torna as comparações entre dados mais confiáveis.
- c) A base zero serve essencialmente para ajustar o parâmetro *alpha* de transparência da linha de tendência temporal.
- d) Ela é obrigatória apenas quando o analista decide utilizar o comando `lplot` para dados sazonais.
- e) Seu uso faz com que o gráfico mude de escala linear para escala categórica automaticamente.

Aula 5: FacetGrid

Questão 9

O recurso FacetGrid é uma ferramenta poderosa para a estruturação de relatórios visuais. O que o FacetGrid permite realizar e qual é seu objetivo principal na análise de dados?

- a) Permite ajustar automaticamente o intervalo de confiança de regressões lineares sem alterar os gráficos.
- b) Permite converter e transformar séries temporais mal formatadas por meio do método `pd.to_datetime()`.
- c) Permite dividir visualizações em vários gráficos menores, onde cada gráfico representa uma categoria diferente dos dados, facilitando a comparação de padrões entre grupos.
- d) Serve para unir todos os pontos de dados dispersos em um único hexágono centralizado para mitigar o *overplotting*.
- e) É utilizado para zerar a base do eixo Y em gráficos de área de grande escala.

Questão 10

As vantagens da utilização de estruturas baseadas em FacetGrid trazem impactos diretos na qualidade da entrega de um projeto de dados. De acordo com o material de apoio, quais são os benefícios diretos do uso dessa ferramenta?

- a) Redução do volume de dados em disco e otimização de consultas SQL.
- b) Organização visual dos dados, comparações mais claras, melhor interpretação de categorias e facilitação de análises exploratórias.
- c) Exclusão automatizada de outliers e cálculo instantâneo da linha de tendência de regressão.
- d) Substituição completa de qualquer manipulação de datas no Pandas e fixação da base zero.
- e) Aumento da poluição visual e centralização de múltiplos grupos em uma única linha de dispersão.

Gabarito

1. **B**
2. **C**
3. **C**
4. **B**
5. **B**
6. **C**
7. **C**
8. **B**
9. **C**
10. **B**